TÀI LIỆU KIẾN TRÚC KỸ THUẬT

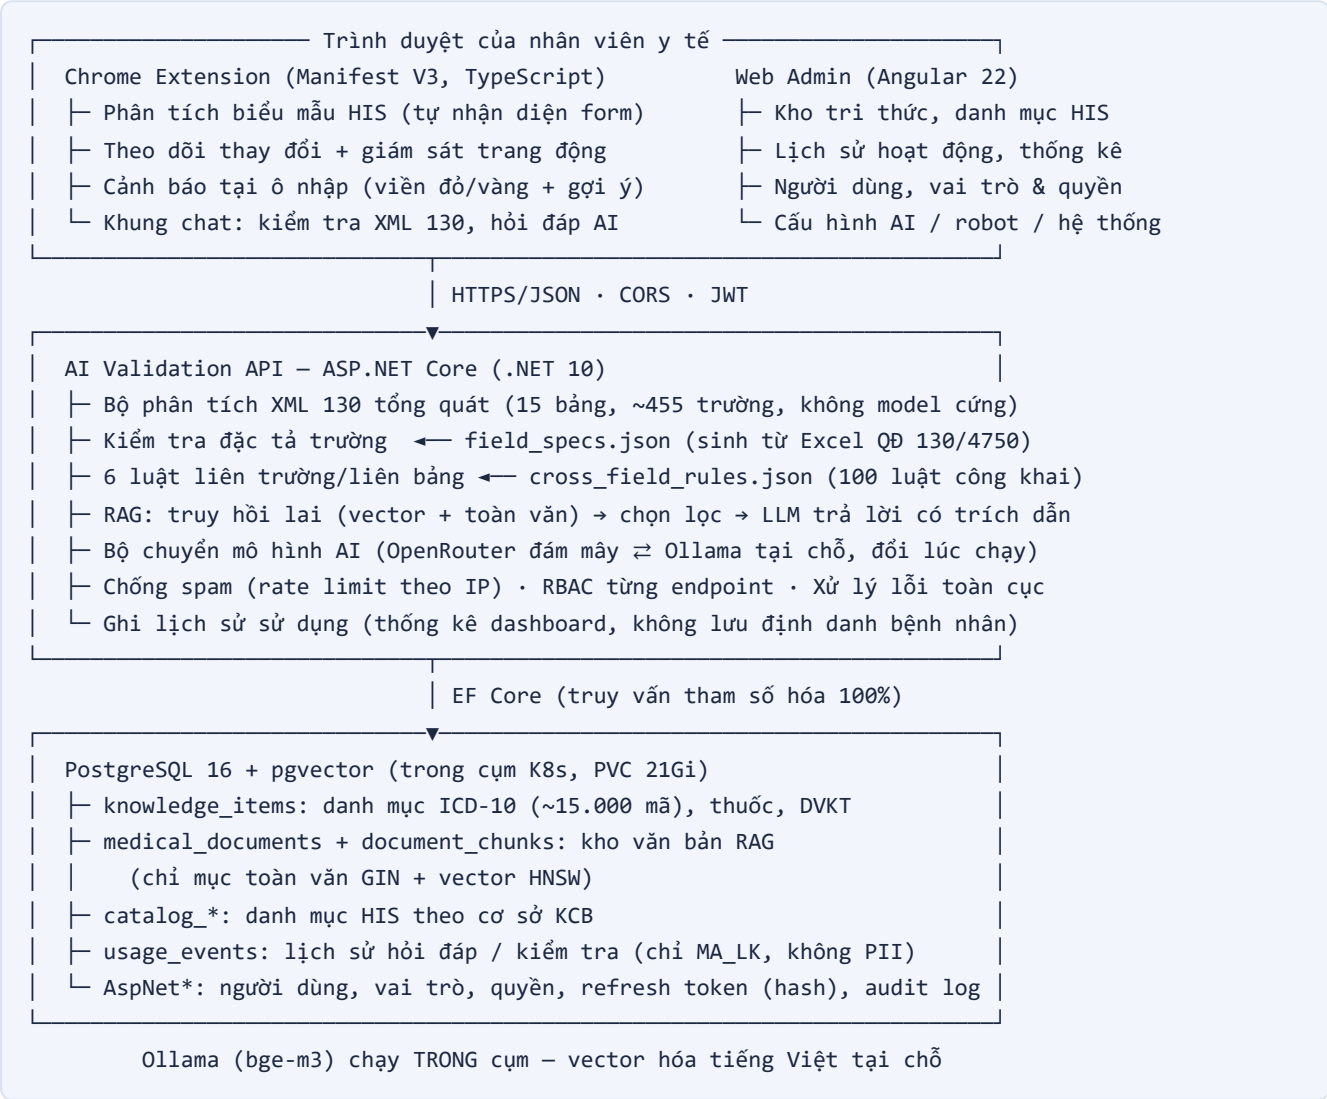
Sản phẩm: ZeroCheck AI — Chiến binh y tế số

Bài toán: Chặn lỗi hồ sơ khám chữa bệnh BHYT (chuẩn XML 130) **trước khi** gửi lên cổng giám định BHXH, tránh bị xuất toán chi phí.

Hệ thống đang chạy thật: https://cbyts.vnpt.vn (VNPT Cloud Kubernetes)

---

1. Kiến trúc tổng quan (3 lớp)



Nguyên tắc xuyên suốt: *Luật quyết định — AI tư vấn.* Mọi kết luận "đạt/không đạt", cờ "nguy cơ xuất toán" đều do bộ máy luật (deterministic) tính; AI chỉ tổng hợp nhận định, xếp ưu tiên sửa và trả lời ngôn ngữ tự nhiên có trích dẫn.

2. Thành phần & công nghệ

Thành phần	Công nghệ	Vai trò
Chrome Extension	Manifest V3, TypeScript, Vite	Cảnh báo nhập liệu thời gian thực trên HIS; chat kiểm tra hồ sơ
Web Admin	Angular 22 (standalone, signals), Angular Material 3	Quản trị vận hành, thống kê, phân quyền
API	ASP.NET Core (.NET 10), EF Core	Rule engine, RAG, xác thực, cấu hình runtime
CSDL	PostgreSQL 16 + pgvector	Dữ liệu danh mục, kho văn bản, chỉ mục toàn văn (GIN) + vector (HNSW)
Embedding	Ollama + bge-m3 (trong cụm)	Vector hóa tiếng Việt — dữ liệu không rời hạ tầng
LLM	OpenRouter (GPT/Claude/Llama…) hoặc Ollama local	Sinh câu trả lời/nhận định; đổi nhà cung cấp lúc vận hành
Hạ tầng	VNPT Cloud Kubernetes (namespace `cbyts`), ingress TLS	Chạy production

3. Ba luồng xử lý chính

Luồng 1 — Cảnh báo nhập liệu thời gian thực

1. Extension tự nhận diện form HIS (theo nhãn/thuộc tính — không cấu hình cứng theo màn hình), bắt sự kiện nhập/sửa kể cả trường do JavaScript sinh động.
2. Luật cục bộ (định dạng, bắt buộc, so sánh ngày) chạy ngay trong trình duyệt — phản hồi **< 50 ms**.
3. Luật sâu (ICD-10 theo giới tính/tuổi, danh mục cơ sở, liên trường) gọi API. Việc nhập liệu **không bao giờ phải dừng chờ AI**.

Luồng 2 — Kiểm tra hồ sơ XML 130

1. Nạp file qua khung chat (hoặc gõ mã bệnh nhân — hệ thống tự lấy XML từ HIS); hỗ trợ **kiểm tra theo lô** kèm đối chiếu chéo (trùng giường, trùng giờ bác sĩ, trùng đợt điều trị).
2. Bộ phân tích **tổng quát**: nhận diện bản ghi theo quy tắc "phần tử có toàn bộ con là nút lá" → đọc đủ 15 bảng ~455 trường mà không viết mã riêng từng bảng. Bộ Y tế điều chỉnh chỉ tiêu → nạp file Excel đặc tả mới trên web admin, **không sửa code**.
3. Kiểm tra đặc tả từng trường + 6 nhóm luật liên bảng (thẻ BHYT, trình tự thời gian, tài chính, chẩn đoán, liên kết hồ sơ, logic nội/ngoại trú). Các luật chạy **độc lập, an toàn khi lỗi**.
4. Kết quả dạng cây 8 nhóm, từng vấn đề kèm mã luật, mức độ, vị trí bảng/trường/dòng, gợi ý sửa, cờ nguy cơ xuất toán. Toàn bộ **< 200 ms**/hồ sơ (không AI).

Luồng 3 — Hỏi đáp văn bản y tế (RAG)

1. **Nạp:** văn bản cắt đoạn ~1.200 ký tự (không đứt câu), đánh chỉ mục toàn văn + vector.
2. **Tìm 2 chiều:** quét rộng 25–40 đoạn — theo nghĩa (pgvector, câu hỏi diễn đạt khác vẫn tìm ra) + theo từ khóa (ưu tiên từ hiếm).

3. **Chọn lọc:** AI chấm điểm liên quan, mỗi văn bản tối đa 3 đoạn — văn bản ngắn không bị văn bản nghìn trang lấn át.
4. **Trả lời có kiểm soát:** chỉ theo trích đoạn, dẫn `[Nguồn n]`; thiếu căn cứ thì nói thẳng "không tìm thấy". Văn bản ngoài khoảng hiệu lực tự bị loại khỏi trích dẫn.

4. Định hướng Cloud Native

Tiêu chí	Hiện trạng
Container hóa	Docker image cho API + web admin; mirror image qua ECR
Điều phối	Kubernetes trên VNPT Cloud (namespace `cbyts`, cụm 3 node)
Stateless & scale ngang	API không giữ trạng thái phiên — thêm replicas là tăng sức tải; PostgreSQL là điểm chung duy nhất
Cấu hình 12-factor	Chuỗi kết nối, API key qua **biến môi trường**; không có secret trong image
Cấu hình bền	Mọi cấu hình vận hành (đặc tả XML 130, ngưỡng chống spam, chế độ AI, lịch ICD, dữ liệu ICD) ghi ra **PVC** — pod khởi động lại không mất
Health check	`GET /api/health` cho liveness probe / load balancer
Di trú CSDL	EF migration **tự áp khi khởi động** (idempotent) — deploy không cần thao tác DB thủ công
CI/CD	2 repo = 2 pipeline độc lập; push tag → build image → deploy K8s (chi tiết ở tài liệu Cài đặt & Vận hành)
AI cloud-native	pgvector + Ollama chạy **trong cụm** — pipeline RAG không phụ thuộc dịch vụ ngoài
Thích ứng hạ tầng	Load balancer VNPT cắt kết nối im lặng ~5s; endpoint hỏi đáp AI (15–18s) stream keepalive để giữ kết nối — xử lý ở server, client không phải sửa

5. Quyết định thiết kế đáng chú ý

1. **RAG thay vì fine-tune:** công văn y tế đổi hằng tháng — nạp file là dùng ngay, truy vết được nguồn, không tốn chi phí huấn luyện, dữ liệu nằm trong CSDL của đơn vị và xóa được.
2. **Đặc tả 2 lớp:** `field_specs.json` + `cross_field_rules.json` là dữ liệu (sinh bán tự động bằng AI từ 16 sheet Excel của Bộ Y tế, rà tay trường trọng yếu) — quy định đổi thì đổi dữ liệu, không biên dịch lại.
3. **Không lưu hồ sơ bệnh án:** file XML kiểm xong là bỏ; CSDL chỉ chứa danh mục + văn bản quy phạm; nhật ký và lịch sử chỉ ghi mã liên kết MA_LK (chi tiết ở Báo cáo bảo mật).
4. **Một khuôn cấu hình runtime:** dịch vụ giữ trạng thái trong bộ nhớ → ghi bền PVC → sửa từ web admin qua API có kiểm soát quyền → áp dụng ngay — dùng thống nhất cho 5 nhóm cấu hình.
5. **Đổi mô hình AI không sửa code:** provider pattern; `temperature = 0` cho tính nhất quán khi kiểm tra.

6. Mã nguồn

Repo	Nội dung
`hackathon-api-validation`	API .NET 10 + k8s manifest + tài liệu (`docs/`)
`hackathon-web-admin`	Web admin Angular 22
`hackathon-extension-his`	Chrome Extension MV3

Tài liệu chi tiết trong repo API: `docs/ARCHITECTURE-V2.md` , `AIValidation.Api/docs/ARCHITECTURE.md` , `docs/DECISIONS.md` .