TÀI LIỆU MINH CHỨNG SỬ DỤNG AI

Tài liệu gồm 2 phần: **(I) AI trong sản phẩm** — dùng ở đâu, prompt nguyên văn, log chạy thật trên production; **(II) AI trong quá trình phát triển** — quy trình làm việc với AI agent, nhật ký, tác động đến thời gian/năng suất.

PHẦN I — AI TRONG SẢN PHẨM

1. Các điểm ứng dụng

#	Tính năng	Thành phần	Mô hình
1	Hỏi đáp văn bản y tế có trích dẫn (RAG)	`AssistantService` + truy hồi lai pgvector/toàn văn	LLM (OpenRouter hoặc Ollama) + bge-m3
2	Nhận định nguy cơ xuất toán hồ sơ XML 130	`Xml130ValidationService`	LLM (bật mới chạy)
3	Chấm điểm chọn lọc đoạn truy hồi (rerank)	`DocumentReranker`	LLM
4	Validate form nhập liệu (luật sâu)	`ValidationService` + PromptBuilder	LLM + knowledge context

Nguyên tắc phân vai: cái gì kiểm *chắc chắn* được thì dùng **luật** (455 đặc tả + 100 luật — tất định, chạy lại luôn ra một kết quả, chi phí 0). AI chỉ tổng hợp nhận định, xếp ưu tiên sửa, trả lời ngôn ngữ tự nhiên. **Cờ "nguy cơ xuất toán" luôn do bộ máy luật tính — AI không có quyền phán hồ sơ đạt/không đạt.** AI đặt `temperature = 0` để nhất quán.

2. Kiến trúc AI: RAG thay vì fine-tune

Tiêu chí	Fine-tune	RAG (đã chọn)
Công văn mới	Huấn luyện lại (giờ→ngày, tốn GPU)	Nạp file → dùng ngay
Truy vết nguồn	Không thể	Trích dẫn từng đoạn `[Nguồn n]`
Bịa đặt	Khó kiểm soát	Ràng buộc "chỉ theo trích đoạn" + từ chối khi thiếu căn cứ
Dữ liệu nhạy cảm	Trộn vào trọng số mô hình	Nằm trong CSDL đơn vị, xóa được

Pipeline: chia đoạn ~1.200 ký tự (không đứt câu) → truy hồi lai (vector bge-m3 **chạy trong cụm** + toàn văn + từ khóa hiếm, pool 25–40 đoạn) → AI chấm điểm giữ 5 đoạn đúng nhất (mỗi văn bản ≤ 3 đoạn — văn bản ngắn không bị lấn át) → sinh trả lời có kiểm soát.

3. Prompt gửi mô hình (nguyên văn từ mã nguồn)

Hỏi đáp RAG — system prompt:

```
Bạn là trợ lý nghiệp vụ BHYT cho nhân viên y tế Việt Nam. CHỈ trả lời dựa trên các trích đoạn
văn bản được cung cấp; nếu văn bản không đủ thông tin, nói rõ là không tìm thấy căn cứ.
Khi trả lời phải dẫn số nguồn dạng [Nguồn 1], [Nguồn 2] – CHỈ dẫn những nguồn bạn thực sự
lấy thông tin, bỏ qua nguồn không liên quan tới câu hỏi. Trả lời ngắn gọn bằng tiếng Việt.
```

Nhận định hồ sơ XML 130 — system prompt:

```
Bạn là chuyên gia giám định BHYT Việt Nam, am hiểu QĐ 130/QĐ-BYT, QĐ 4750/QĐ-BYT và quy trình
giám định của BHXH. Trả lời ngắn gọn, chính xác, bằng tiếng Việt.
```

User prompt liệt kê tối đa 40 lỗi **do rule engine phát hiện** (AI không tự phán), yêu cầu đánh giá nguy cơ và 3 việc cần sửa theo thứ tự ảnh hưởng tài chính, tối đa 150 từ.

(Toàn bộ prompt template khác — validate form v1 — nằm trong repo tại `AIValidation.Api/Prompts/*.md`, code đọc lúc runtime.)

4. Log chạy thật trên production (bắt live 28/07/2026)

Request thật tới `POST https://cbyts.vnpt.vn/api/assistant/ask`, log trích từ pod bằng `kubectl -n cbyts logs deployment/api-validation`:

```
16:38:24.708  IEmbeddingService  Start POST → Ollama bge-m3 (vector hoá câu hỏi)
16:38:24.957  ← embedding trả về (248 ms)
16:38:24.961  EFCore  SELECT ... document_chunks WHERE "SearchVector" @@ plainto_tsquery(@q)
              -- truy hồi lai: pgvector + toàn văn, CHỈ lấy văn bản còn hiệu lực
16:38:28.984  LLMProvider → OpenRouter 'openai/gpt-4o-mini'
16:38:28.984  Sending request: UserPromptLength=6039
16:38:31.877  ✓ Response received: CompletionTokens=169
```

Chỉ số	Giá trị đo thật
Câu hỏi	"Thẻ BHYT hết hạn trong đợt điều trị nội trú thì chi phí sau ngày hết hạn được thanh toán thế nào?"
Trả lời	"...thanh toán đến ngày ra viện, **tối đa không quá 15 ngày** kể từ ngày thẻ hết hạn **[Nguồn 1]**" — trích dẫn khớp QĐ 130/QĐ-BYT trong `citations`
Nội dung gửi AI	6.039 ký tự (vai trò + trích đoạn + câu hỏi) · sinh 169 token
Tổng độ trễ đầu–cuối	9,49 giây · cờ `"fromLlm": true` do API tự đặt

Cách BGK tự tái lập: gọi API hỏi đáp trên hệ thống thật rồi xem *Lịch sử hoạt động* trên web admin — mỗi lượt lưu nguyên câu hỏi/câu trả lời/nguồn trích dẫn.

PHẦN II — AI TRONG QUÁ TRÌNH PHÁT TRIỂN

1. Cách tổ chức: 1 lập trình viên + 1 AI agent

Toàn bộ 3 repo (API .NET, web admin Angular, Chrome extension) được phát triển theo mô hình **người ra đề & duyệt — AI agent (Claude Code) thực thi**: agent đọc tài liệu kiến trúc trong repo, viết code, tự biên dịch kiểm chứng, tự viết migration, sinh tài liệu và slide; con người quyết định yêu cầu, review và nghiệm thu trên sản phẩm chạy thật.

Cấu hình kỷ luật cho agent (có trong repo, BGK kiểm chứng được):

- `CLAUDE.md` từng repo: quy ước kiến trúc (SRP/DI), *mọi thông báo người dùng bằng tiếng Việt*, và đặc biệt quy định **chống file rác** (bài học từ giai đoạn đầu: 60 file .md rác do AI sinh đã phải dọn thủ công — sau đó đưa thành luật, agent tuân thủ).
- `tasks/task-0NN.md`: mỗi yêu cầu một file đề bài gốc.
- Quy trình mỗi tính năng: đọc docs → lập kế hoạch (plan) → người duyệt → code → tự build 0 lỗi → deploy CI/CD → nghiệm thu trên production.

2. Ví dụ prompt điều khiển agent (nguyên văn, rút gọn)

- *"Khi import danh mục HIS thì không tự động import vào kho tri thức; màn hình danh mục HIS ở mỗi dòng có thêm nút nạp vào kho tri thức, có thể chọn nhiều dòng bằng checkbox để nạp"* → agent tự thiết kế endpoint + UI + hỏi lại 2 lựa chọn nghiệp vụ trước khi làm.
- *"Khi trả lời câu hỏi hay check XML130 nên ghi lại lịch sử, rồi thống kê ở dashboard bằng biểu đồ, xem theo khoảng thời gian như hôm nay, tuần này, tháng trước..."* → agent tự tạo bảng, migration viết tay, endpoint thống kê, biểu đồ thuần CSS.
- *"ICD trên form toàn báo 'không tồn tại', local thì được, online bị thiếu gì?"* → agent truy vết ra lỗi đường dẫn dữ liệu trong container và sửa tận gốc (mục 3).

3. Nhật ký toàn bộ dự án (dựng từ git log thật, 13/07 → 29/07/2026)

Toàn bộ mốc dưới đây trích từ lịch sử commit của các repo (BGK có thể đối chiếu `git log`). **17 ngày, 1 lập trình viên + AI agent, từ số 0 đến hệ thống production.**

Giai đoạn 1 — Nền móng v1 (13/07 – 16/07)

Ngày	Việc hoàn thành cùng AI agent
13/07	Khởi tạo 2 repo (API .NET + Chrome extension); khung kiến trúc v1: extension bắt sự kiện form HIS → API validate form snapshot → trả lỗi/cảnh báo theo trường
14/07	Chuẩn hóa response validation, xử lý lỗi tập trung, tài liệu cấu hình
16/07	Hoàn thiện bộ luật ICD cho form (tồn tại / hết hiệu lực / giới tính / độ tuổi / chẩn đoán chính)

Giai đoạn 2 — Bước nhảy v2: XML 130 + RAG (16/07 – 18/07)

Ngày	Việc hoàn thành cùng AI agent
16/07	**Engine kiểm tra hồ sơ XML 130** (parser tổng quát 15 bảng) + **RAG văn bản y tế**; đặt tên đề tài "Chiến binh y tế số"; đồng bộ ICD tự động từ nguồn công bố; **AI sinh bộ đặc tả 455 trường + 100 luật từ 16 sheet Excel QĐ 130/4750**
17/07	RAG nạp .docx/.pdf/.xlsx; phân loại ICD làm chẩn đoán chính theo danh mục TT06; tự giải mã file XML mã hóa base64; **danh mục HIS: import 25 loại file Excel + luật đối chiếu hồ sơ với danh mục đúng cơ sở**; luật chuyển tuyến XML13 + người chỉ định (CCHN); sửa quy ước giới tính theo form HIS thật
18/07	RAG thêm bước **chấm điểm chọn lọc (rerank)** chống văn bản lớn lấn át; đổi model mặc định sang gpt-4o-mini; **RBAC giai đoạn 1** (JWT, vai trò, quyền chi tiết); middleware xử lý client hủy request

Giai đoạn 3 — Lên mây & web admin (23/07 – 27/07)

Ngày	Việc hoàn thành cùng AI agent
23/07	**Triển khai VNPT Cloud K8s** lần đầu; worker chỉ mục ngữ nghĩa chạy nền
24/07	PostgreSQL 16 + **pgvector trong cụm** (PVC 21Gi); mirror image qua ECR; **Ollama trong cụm** (bge-m3 — vector hóa tại chỗ); khởi tạo **web admin Angular 22**; cấu hình LLM + user-secrets
25/07	Hoàn thiện CI/CD (sed ECR_ID mọi manifest); di trú tài khoản quản trị; **quên mật khẩu qua email SMTP**; **phát hiện & xử lý LB VNPT cắt kết nối im lặng 5s → stream keepalive** cho hỏi đáp AI; fix gỡ văn bản phải xóa sạch chỉ mục HNSW; **nạp lại đặc tả XML 130 runtime** (điều kiện kiểm đổi theo file Excel); health probe `/api/health`
26–27/07	Web admin đủ vòng đời vận hành: kho tri thức + chỉ mục ngữ nghĩa, danh mục HIS, tải văn bản từ vbpl.vn, người dùng – vai trò – quyền, nhật ký kiểm toán, cấu hình AI/robot, **ngưỡng chống spam chỉnh runtime**, responsive

Giai đoạn 4 — Hoàn thiện chấm thi (28/07 – 29/07)

Ngày	Việc hoàn thành cùng AI agent
28/07	Tách "nạp kho tri thức" khỏi import danh mục (nạp/gỡ từng dòng + chọn nhiều dòng); **quyền mới** `Catalog.Knowledge` seed tự động + chặn endpoint + ẩn nút; slide báo cáo (HTML tương tác + PPTX tự sinh bằng script thuần Node); bắt **log AI production** làm minh chứng
29/07 sáng	Việt hóa ~30 thuật ngữ trên slide; hội thoại demo tự chạy theo phiên thật; tăng cỡ chữ + hiệu ứng; slide đối chiếu 7 tiêu chí chấm của BTC
29/07 ~14:00	**Fix lỗi production:** mọi mã ICD báo "không tồn tại" trên online — agent truy ra gốc: hàm tìm thư mục dữ liệu leo cây source, container không có cây source → nạp 0 mã; sửa: ship 7MB dữ liệu ICD theo image + lưu bền PVC (nút "Đồng bộ ICD" sống lại luôn)
29/07 ~15:00	**Màn "Lịch sử hoạt động"** trọn gói full-stack trong ~1 giờ: bảng + migration viết tay + 2 endpoint + màn Angular + dialog xem lại nguyên phản hồi (chỉ lưu MA_LK, kèm mã đơn vị/nhân viên)
29/07 ~16:00	**Chẩn đoán qua triệu chứng người dùng:** trang trống + `ERR_BLOCKED_BY_CLIENT` → nhận ra **adblock của trình duyệt chặn URL chứa** `/stats/` (bộ lọc EasyPrivacy) → đổi route `api/stats` → `api/dashboard`

Ngày	Việc hoàn thành cùng AI agent
29/07 trong ngày	Theme tối neon toàn web admin (sáng/tối) + **trang chủ giới thiệu** nhúng trình chiếu; biểu đồ hoạt động theo khoảng thời gian (1 nút chọn); chuẩn hóa UI (nút Lưu một chuẩn, input bằng chiều cao nút); bỏ tự đoán ngày hiệu lực → nhập tay trên admin; **tour onboarding 3 bước lần đầu cho nhân viên HIS**; bộ 8 tài liệu nộp BTC (md/docx/pdf) — **3 lần deploy production trong ngày**

4. AI tăng tốc số hóa văn bản quy phạm

Bộ đặc tả **455 trường** (`field_specs.json`) và danh mục **100 luật** (`cross_field_rules.json`) được **AI sinh bán tự động từ 16 sheet Excel** đặc tả QĐ 130/QĐ 4750 của Bộ Y tế, sau đó con người rà tay các trường trọng yếu. Đây là phần nếu gõ tay ước tính mất **nhiều ngày công**, thực tế hoàn thành trong **buổi làm việc** — và tạo ra kiến trúc "quy định là dữ liệu": QĐ mới chỉ cần nạp lại file, không sửa code.

5. Tác động (thời gian / năng suất)

Chỉ dấu	Giá trị
Nhân lực	1 lập trình viên + AI agent
Phạm vi hoàn thành	3 ứng dụng production (API + web admin + extension), CI/CD, hạ tầng K8s
Vòng lặp ý tưởng → production	tính bằng **giờ** (điển hình: màn Lịch sử hoạt động ~1 giờ; ngày cao điểm 3 lần deploy)
Chất lượng giữ bằng	agent tự biên dịch 0 lỗi trước khi bàn giao; quy ước CLAUDE.md; con người nghiệm thu trên hệ thống thật
Sản phẩm phụ do AI sinh	slide 17 trang (HTML + PPTX), bộ tài liệu nộp BTC (md/docx/pdf), tài liệu kiến trúc/vận hành trong `docs/`